

Aprendizagem de Máquina Aplicada ao Diagnóstico de Transtornos Mentais: uma Comparação entre Árvore de Decisão e Random Forest

Renata Mantovani¹, Fábio Dantas², Diogo Fernando³

Unifacisa – Centro Universitário. Sistemas de Informação - Noturno.
Campina Grande – PB – Brasil

renata.mantovani@maisunifacisa.com.br¹,

fabio.dantas@maisunifacisa.com.br²,

diogo.moura@maisunifacisa.com.br³.

Abstract. *This work presents the development of a machine learning model for the classification of mental disorders based on clinical symptoms. Data from the Diseases and Symptoms dataset, available on Kaggle, were used, filtering three conditions: panic disorder, anxiety, and schizophrenia, totaling 2,997 samples and 21 relevant symptoms (post-cleaning). The Decision Tree and Random Forest algorithms were implemented and compared using an 80/10/10 data split and 5-fold cross-validation. The results indicate that Random Forest achieved superior performance, reaching an accuracy of 97%, with precision, recall, and F1-Score at similar levels, and an overfitting of only 0.96%. The results demonstrate that the model is capable of correctly classifying mental disorders based on the presented symptoms.*

Resumo. *Este trabalho apresenta o desenvolvimento de um modelo de aprendizagem de máquina para a classificação de transtornos mentais a partir de sintomas clínicos. Foram utilizados dados do dataset Diseases and Symptoms, disponível no Kaggle, filtrando três condições: transtorno do pânico, ansiedade e esquizofrenia, totalizando 2.997 amostras e 21 sintomas relevantes (pós-limpeza). Os algoritmos Árvore de Decisão e Random Forest foram implementados e comparados utilizando divisão de dados na proporção 80/10/10 e validação cruzada com 5 folds. Os resultados obtidos indicam que o Random Forest apresentou desempenho superior, alcançando acurácia de aproximadamente 97%, bem como a precisão, recall e F1-Score de maneira aproximada, com overfitting de apenas 0,96%. Os resultados demonstram que o modelo é capaz de classificar corretamente os transtornos mentais a partir dos sintomas apresentados.*

1. Introdução

O diagnóstico de transtornos mentais é um processo complexo que depende da identificação e interpretação de um conjunto de sintomas clínicos. Erros ou atrasos nesse processo podem impactar diretamente a qualidade de vida dos pacientes, tornando relevante o desenvolvimento de ferramentas que auxiliem na tomada de decisão clínica.

Nesse contexto, a aprendizagem de máquina surge como uma abordagem promissora, permitindo que modelos computacionais aprendam padrões a partir de dados históricos e realizem previsões sobre novos casos. Algoritmos como Árvore de Decisão e Random Forest têm sido amplamente utilizados em problemas de classificação na área da saúde, por apresentarem bom desempenho e alta

interpretabilidade.

Este trabalho tem como objetivo desenvolver e avaliar um modelo de aprendizagem de máquina capaz de classificar três transtornos mentais — transtorno do pânico, ansiedade e esquizofrenia — a partir de um conjunto de sintomas clínicos.

Para isso, foi utilizado o dataset [*Diseases and Symptoms*](#), disponível na plataforma Kaggle, que contém 773 doenças únicas, 377 sintomas e aproximadamente 246.000 registros gerados artificialmente, preservando a severidade dos sintomas e a probabilidade de ocorrência de cada doença. Devido a limitações de hardware, foi utilizado um subconjunto do dataset original. Após a filtragem e limpeza dos dados, foram obtidas 2.997 amostras com 21 sintomas relevantes, sobre as quais os algoritmos Árvore de Decisão e Random Forest foram treinados, validados e comparados.

2. Metodologia


O presente trabalho foi desenvolvido em linguagem Python utilizando o ambiente Jupyter Notebook, como atividade de conclusão da disciplina "Elaborar um modelo de aprendizagem de máquina" do curso de Sistemas de Informação. As bibliotecas utilizadas foram pandas e numpy para manipulação e análise dos dados, matplotlib e seaborn para visualização, e scikit-learn para a implementação dos modelos de aprendizagem de máquina.

Devido a limitações de hardware, foi utilizada uma versão reduzida do dataset original, composta pelas primeiras 171.524 linhas, intervalo que contém todos os registros das três doenças selecionadas. Após o carregamento e filtragem inicial, o dataset resultante apresentou 2.997 amostras distribuídas entre as três classes: 1.198 registros de ansiedade, 909 de transtorno do pânico e 890 de esquizofrenia, totalizando 378 colunas.

Na etapa de pré-processamento, foram realizadas as seguintes operações: filtragem das três doenças de interesse, remoção das colunas de sintomas cujos valores eram sempre zero — ou seja, sintomas que não apresentaram nenhuma ocorrência para as doenças selecionadas — e verificação da qualidade dos dados. Confirmou-se a ausência de valores nulos e que todos os sintomas possuíam valores estritamente binários (0 ou 1), indicando respectivamente a ausência ou presença do sintoma. Após o pré-processamento, o dataset final contou com 2.997 amostras e 21 sintomas relevantes, mantendo a mesma distribuição de classes apresentada anteriormente, conforme ilustrado na Figura 01.

Por fim, os dados foram divididos seguindo a proporção 80/10/10, destinando 80% das amostras para treino, 10% para validação e 10% para teste, utilizando estratificação para garantir que a proporção entre as três classes fosse mantida em cada conjunto. A divisão resultou em 2.397 amostras para treino, 300 para validação e 300 para teste.

Figura 01: Gráfico de Distribuição de dados



3. Conjunto de Treinamento

Para o treinamento dos modelos, foram utilizados os algoritmos Árvore de Decisão e Random Forest, ambos implementados por meio da biblioteca scikit-learn. A Árvore de Decisão foi configurada com profundidade máxima de 5 níveis ($max_depth=5$), exigindo no mínimo 10 amostras para que um nó pudesse ser dividido ($min_samples_split=10$) e no mínimo 5 amostras em cada folha ($min_samples_leaf=5$). Essas restrições foram aplicadas deliberadamente para evitar que a árvore crescesse de forma excessiva e decorasse os dados de treino, controlando assim o *overfitting*.

O Random Forest foi configurado com 100 árvores ($n_estimators=100$), profundidade máxima de 10 níveis por árvore ($max_depth=10$) e utilização de todos os núcleos de processamento disponíveis ($n_jobs=-1$). Por ser um modelo *ensemble* que combina os resultados de múltiplas árvores, o Random Forest é naturalmente mais robusto ao *overfitting* em comparação à Árvore de Decisão isolada. Em ambos os modelos foi definido $random_state=50$ para garantir a reprodutibilidade dos resultados.

Para a validação dos modelos, foi aplicada a técnica de validação cruzada com 5 folds utilizando o *StratifiedKFold*, que preserva a proporção das classes em cada fold. Os resultados obtidos demonstraram desempenhos distintos entre os dois algoritmos. A Árvore de Decisão apresentou acurácias por *fold* de 0.8938, 0.8417, 0.8873, 0.9081 e 0.9019, resultando em média de 0.8865 e desvio padrão de 0.0235.

O Random Forest, por sua vez, apresentou acurácias de 0.9604, 0.9688, 0.9749, 0.9770 e 0.9645, com média de 0.9691 e desvio padrão de 0.0062. O baixo desvio padrão do Random Forest indica que o modelo se comportou de forma consistente ao longo dos folds, enquanto a Árvore de Decisão apresentou maior variação, sugerindo menor estabilidade na generalização dos dados.

4. Conjunto de Validação

Após o treinamento, os modelos foram avaliados sobre o conjunto de validação, composto por 300 amostras, com o objetivo de verificar o desempenho antes da avaliação final.

A Árvore de Decisão apresentou acurácia de 86,33%, precisão de 0,8825, recall de 0,8633 e F1-Score de 0,8620 no conjunto de validação. Analisando o desempenho por classe, observa-se que o modelo identificou com precisão perfeita os casos de transtorno do pânico (precisão de 1,00), porém com recall de apenas 0,73, indicando que 27% dos casos reais dessa condição foram classificados incorretamente. A esquizofrenia, por outro lado, apresentou recall perfeito (1,00), mas com precisão menor (0,77), sugerindo que o modelo classificou casos de outras doenças como esquizofrenia.

O Random Forest demonstrou desempenho consideravelmente superior, alcançando acurácia de 97,33%, precisão de 0,9735, recall de 0,9733 e F1-Score de 0,9734. O modelo se destacou especialmente na classificação da esquizofrenia, atingindo precisão e recall perfeitos (1,00) para essa classe, e desempenho igualmente elevado para ansiedade e transtorno do pânico.

5. Conjunto de Testes

A avaliação final foi realizada sobre o conjunto de teste, composto por 300 amostras que permaneceram completamente isoladas durante todo o processo de treinamento e validação, simulando dados inéditos para o modelo.

A Árvore de Decisão apresentou acurácia de 85,67%, precisão de 0,8796, recall de 0,8567 e F1-Score de 0,8564. O comportamento por classe foi semelhante ao observado na validação — o transtorno do pânico novamente apresentou precisão perfeita (1,00) porém recall de apenas 0,74, indicando que o modelo deixou de identificar 26% dos casos reais dessa condição. A esquizofrenia manteve recall perfeito (1,00) com precisão de 0,75, confirmando a tendência do modelo de classificar casos de outras doenças como esquizofrenia. A ansiedade apresentou o desempenho mais equilibrado entre precisão (0,89) e recall (0,84).

O Random Forest confirmou seu desempenho superior também no conjunto de teste, alcançando acurácia de aproximadamente 97%, precisão de 0,9707, recall de 0,9700 e F1-Score de 0,9701. A esquizofrenia foi a classe com melhor desempenho, atingindo precisão perfeita (1,00) e recall de 0,98. O transtorno do pânico e a ansiedade também apresentaram resultados expressivos, com F1-Score de 0,96 e 0,97 respectivamente.

A consistência entre os resultados obtidos no conjunto de validação e no conjunto de teste reforça a confiabilidade dos modelos, indicando que o desempenho observado não foi resultado de ajuste excessivo aos dados de validação.

6. Resultados


6.1 - Conjunto de Validação Métricas na etapa validação

Figura 02: Matriz de confusão referente à árvore de decisão na etapa validação



As matrizes de confusão obtidas no conjunto de validação, ilustradas nas Figuras 02 e 03, permitem visualizar de forma detalhada os acertos e erros de cada modelo por classe. No caso da Árvore de Decisão, observa-se que o modelo classificou corretamente a totalidade dos casos de esquizofrenia, porém apresentou dificuldade na identificação do transtorno do pânico, confundindo parte significativa desses casos com outras condições. Esse comportamento é consistente com o recall de 0,73 apresentado para essa classe, o mais baixo entre as três.

Figura 03: Matriz de confusão referente à random forest na etapa validação




O Random Forest demonstrou desempenho expressivamente superior em todas as classes. A esquizofrenia foi classificada com perfeição — precisão e recall iguais a 1,00 — enquanto ansiedade e transtorno do pânico apresentaram métricas acima de 0,95 em todos os indicadores. A matriz de confusão do Random Forest evidencia uma diagonal principal predominante, com pouquíssimos erros de classificação, refletindo a acurácia de 97,33% obtida nesse conjunto.

A comparação entre as duas matrizes reforça a superioridade do Random Forest, que além de obter mais acertos, distribui seus erros de forma mais equilibrada entre as classes, sem concentrá-los em uma condição específica como ocorre na Árvore de Decisão.

6.2 - Conjunto de Teste e suas métricas

Figura 04: Matriz de confusão referente à árvore de decisão na etapa testes




A avaliação final sobre o conjunto de teste, composto por 300 amostras inéditas, confirmou os padrões observados durante a validação. As matrizes de confusão obtidas, ilustradas nas Figuras 04 e 05, evidenciam o comportamento de cada modelo frente a dados que não participaram de nenhuma etapa anterior do processo.

A matriz de confusão da Árvore de Decisão revelou que, dos 120 casos reais de ansiedade, 101 foram classificados corretamente e 19 foram confundidos com esquizofrenia. Dos 91 casos de transtorno do pânico, apenas 67 foram identificados corretamente — 13 foram classificados como ansiedade e 11 como esquizofrenia, confirmando o recall de 0,74 como o mais baixo entre as três classes. A esquizofrenia foi a única classe categorizada sem nenhum erro, com todos os 89 casos identificados corretamente, o que explica seu recall perfeito (1,00) apesar da precisão mais baixa

(0,75), já que casos de outras doenças foram indevidamente atribuídos a ela. A acurácia geral do modelo foi de 85,67%.

Figura 05: Matriz de confusão referente à random forest na etapa testes




O Random Forest apresentou desempenho consideravelmente superior. Dos 120 casos de ansiedade, 115 foram classificados corretamente, com apenas 5 confundidos com transtorno do pânico e nenhum com esquizofrenia. Dos 91 casos de transtorno do pânico, 89 foram identificados corretamente, com apenas 2 classificados como ansiedade. A esquizofrenia teve 87 dos 89 casos classificados corretamente, com apenas 1 confundido com ansiedade e 1 com transtorno do pânico. Esses resultados refletem a acurácia de 97,00% e o F1-Score médio de 0,97% obtidos pelo modelo.

A comparação entre as duas matrizes evidencia claramente a superioridade do Random Forest — enquanto a Árvore de Decisão concentrou seus erros principalmente no transtorno do pânico, o Random Forest distribuiu os poucos erros cometidos de forma equilibrada entre as classes, sem prejudicar significativamente nenhuma condição específica.


6.3 - Comparações entre as métricas e modelos

Figura 06: Gráficos de barras comparando métricas entre modelos



A Figura 06 apresenta o gráfico comparativo das métricas obtidas por ambos os modelos no conjunto de testes. O Random Forest superou a Árvore de Decisão em todos os indicadores avaliados — acurácia (0,9633 contra 0,8567), precisão (0,9646 contra 0,8796), recall (0,9633 contra 0,8567) e F1-Score (0,9634 contra 0,8564) — com uma diferença aproximada de 10 pontos percentuais em cada métrica.

Figura 07: Diagrama de venn dos sintomas entre as doenças:



O diagrama de Venn apresentado na Figura 07 ilustra a distribuição dos sintomas entre as três condições analisadas, revelando padrões importantes para a compreensão do problema de classificação.

As três doenças compartilham quatro sintomas em comum ao **centro** — *insônia, ansiedade e nervosismo, depressão e sintomas depressivos ou psicóticos* — o que representa o principal desafio para os modelos de classificação, já que esses sintomas isoladamente não são suficientes para distinguir uma condição da outra.

Em relação aos sintomas exclusivos, a esquizofrenia é a doença com maior número de **sintomas privativos**, apresentando seis sintomas que não aparecem nas demais condições: problemas de temperamento, comportamento histérico, baixa autoestima, raiva excessiva, comportamento hostil e delírios ou alucinações. Esse

conjunto de sintomas altamente específicos explica o excelente desempenho dos modelos na classificação desta doença, com *recall* perfeito ou próximo de 1,00 em ambos os algoritmos. A **ansiedade** apresenta **três sintomas exclusivos** — *dor torácica aguda, aumento da frequência cardíaca e dor de cabeça* — enquanto o **transtorno do pânico** se distingue por *respiração acelerada, aperto no peito e tontura*.

Entre os sintomas compartilhados por apenas **duas doenças**, destacam-se os quatro sintomas comuns entre ansiedade e transtorno do pânico — *movimentos involuntários anormais, palpitações, batimento cardíaco irregular e falta de ar* — o que ajuda a explicar a maior dificuldade dos modelos em distinguir essas duas condições entre si. **Ansiedade e esquizofrenia** compartilham apenas o sintoma de medos e fobias, enquanto **transtorno do pânico e esquizofrenia** não apresentam nenhum sintoma exclusivamente compartilhado entre si.

Esses resultados evidenciam que a sobreposição de sintomas entre ansiedade e transtorno do pânico é o principal fator de dificuldade para a classificação, enquanto a esquizofrenia, por possuir o maior conjunto de sintomas exclusivos, é a condição mais facilmente identificada pelos modelos.

Tabela 01 — Comparação de Métricas entre Árvore de Decisão e Random Forest no Conjunto de Teste

Métrica	Árvore de Decisão	Random Forest
Acurácia	0.8567 (85.67%)	0.9633 (96.33%)
Precisão	0.8796	0.9646
Recall	0.8567	0.9633
F1-Score	0.8564	0.9634

Tabela 02: Verificação de overfitting através da acurácia:

Modelo	Treino	Validação	Teste	Diferença
Árvore de Decisão	0.8911	0.8633	0.8567	0.0344
Random Forest	0.9741	0.9567	0.9633	0.0108

A tabela 01 apresenta a comparação direta entre as métricas obtidas pelos dois modelos no conjunto de testes. O Random Forest superou a Árvore de Decisão em todos os indicadores, com destaque para a acurácia, que foi aproximadamente 11 pontos percentuais superior, e para o overfitting, que foi três vezes menor, reforçando que o Random Forest é o modelo mais preciso e confiável para o problema proposto.

Já a tabela 02 apresenta as acurácias obtidas nos conjuntos de treino, validação e teste, bem como a diferença entre treino e teste para cada modelo. A Árvore de Decisão apresentou uma diferença de 3,44% entre treino e teste, valor considerado aceitável para um modelo de classificação. Já o Random Forest apresentou uma diferença ainda menor, de apenas 1,08%, demonstrando excelente capacidade de generalização. Em ambos os casos, a proximidade entre os valores de treino, validação e teste indica que nenhum dos modelos sofreu o overfitting.

7. Random Forest e Seleção de Atributos com SelectKBest:

Ao longo de todas as etapas de avaliação, o Random Forest demonstrou consistentemente desempenho superior à Árvore de Decisão, com acurácia de 96,33% contra 85,67% no conjunto de teste, menor overfitting (1,08% contra 3,44%) e maior estabilidade na validação cruzada, com desvio padrão de 0,0062 contra 0,0235. Esses fatores, combinados com a capacidade natural do algoritmo de resistir ao overfitting por meio da combinação de múltiplas árvores, tornam o Random Forest a escolha mais adequada para o problema de classificação dos três transtornos mentais analisados.

Para verificar se todos os 21 sintomas citados nas doenças estudadas eram de fato necessários, foi aplicada a técnica de seleção de recursos SelectKBest, que identificou os 10 sintomas estatisticamente mais relevantes para a classificação. O modelo foi treinado novamente utilizando apenas esses 10 sintomas e os resultados foram comparados com o modelo original, conforme apresentado no código da figura 08 abaixo:

Figura 08: Trecho de código do Jupyter Notebook

```
# Treino Random Forest com os sintomas selecionados
rf_selected = RandomForestClassifier(n_estimators=100, max_depth=10,
                                   random_state=50, n_jobs=-1)
rf_selected.fit(X_train_selected, y_train)
y_pred_selected = rf_selected.predict(X_test_selected)

# Comparação
print('=== Random Forest - 21 sintomas (original) ===')
calcular_metricas('Random Forest original', y_test, y_pred_rf)

print('=== Random Forest - 10 sintomas (SelectKBest) ===')
calcular_metricas('Random Forest + SelectKBest', y_test, y_pred_selected)
```

O modelo com 10 sintomas alcançou acurácia de 96,00%, precisão de 0,9636, recall de 0,9600 e F1-Score de 0,9599 — uma diferença inferior a 0,5% em relação ao modelo original com 21 sintomas. Esse resultado demonstra que metade dos sintomas disponíveis contribui de forma marginal para a classificação, e que o modelo consegue manter um desempenho praticamente idêntico com menos variáveis.

Diante de todos os resultados apresentados, conclui-se que o Random Forest, em todos os cenários mostrados se apresenta como superior para o diagnóstico das três doenças avaliadas, e mesmo em sua versão reduzida com 10 sintomas, é capaz de classificar corretamente os três transtornos mentais com alto grau de confiabilidade, consolidando-se como o modelo mais robusto, estável e eficiente para o problema proposto.

8. Conclusão

Este trabalho desenvolveu e avaliou dois modelos de aprendizagem de máquina (Árvore de Decisão e Random Forest) para a classificação de três transtornos mentais (ansiedade, transtorno do pânico e esquizofrenia) a partir de sintomas clínicos. Os resultados obtidos demonstram que o Random Forest é o modelo mais adequado para o problema proposto, alcançando as métricas aproximadas de acurácia: 96%, precisão: 0,96, recall: 0,96 e F1-Score de 0,96 no conjunto de testes, com *overfitting* de apenas 1,08%. Esses valores indicam que o modelo é capaz de identificar corretamente os três transtornos com alto grau de confiabilidade.

A superioridade do Random Forest em relação à Árvore de Decisão se justifica pela sua natureza *ensemble*, que combina múltiplas árvores de decisão para produzir previsões mais robustas e estáveis, reduzindo o risco de *overfitting* e aumentando a capacidade de generalização. Adicionalmente, a aplicação de *feature selection* demonstrou que o modelo mantém desempenho praticamente idêntico mesmo com apenas 10 dos 21 sintomas disponíveis, o que reforça sua eficiência e sugere que um conjunto reduzido de sintomas é suficiente para um diagnóstico confiável.

9. Referências Bibliográficas

DHIVYESHRK. **Diseases and Symptoms Dataset**. Kaggle, 2023. Disponível em: <https://www.kaggle.com/datasets/dhivyeshrk/diseases-and-symptoms-dataset>

PANDAS: McKinney, W. **Data Structures for Statistical Computing in Python**. Proceedings of the 9th Python in Science Conference, 2010.

NUMPY: Harris, C. R. et al. **Array programming with NumPy**. Nature, 585, 357–362, 2020.

SCIKIT-LEARN: Pedregosa, F. et al. **Scikit-learn: Machine Learning in Python**. Journal of Machine Learning Research, 12, 2825–2830, 2011.

MATPLOTLIB: Hunter, J. D. **Matplotlib: A 2D graphics environment**. Computing in Science & Engineering, 9(3), 90–95, 2007.

SEABORN: Waskom, M. **Seaborn: statistical data visualization**. Journal of Open Source Software, 6(60), 3021, 2021.

BREIMAN, L. **Random Forests**. Machine Learning, 45, 5–32, 2001.

QUINLAN, J. R. **Induction of Decision Trees**. Machine Learning, 1, 81–106, 1986.